

Legally Subjective

Jusqu’où peut-on prédire les décisions de la Cour suprême
des États-Unis à partir de données publiques ?

Amine Harch El Korane Ghali El Alj

Élèves du lycée français international Louis-Massignon (Bouskoura—Casablanca, Maroc) — expériences, code
et reproductibilité / analyse juridique et lecture doctrinale.

Code et données : github.com/Vitalcheffe/legally-subjective

Résumé en français du rapport de recherche complet (en anglais, 23 pages)

La question, et pourquoi elle compte

La Cour suprême des États-Unis tranche les questions les plus divisives de la société américaine : avortement, port d’armes, discrimination, pouvoirs présidentiels. Ses neuf juges sont nommés à vie précisément pour que leur jugement ne soit *pas* celui d’une machine : la subjectivité judiciaire est, en théorie, le dernier rempart contre l’automatisation de la justice. Nous nous sommes donc demandé jusqu’où cette subjectivité résiste à la mesure : peut-on prédire la décision d’une affaire, ou le vote individuel d’un juge, à partir d’informations publiques — les votes passés, le texte du dossier, le style rédactionnel du juge ? Les deux issues possibles publient : si la prédiction marche, une part importante du jugement est statistique ; si elle échoue sur les cas difficiles, alors la part irréductible — celle qui fait qu’un juge n’est pas un algorithme — est réellement là. Notre réponse est chiffrée des deux côtés, et c’est ce qui fait la valeur du projet.

Les données : un corpus public, gelé et vérifiable

Nous avons assemblé un corpus de **569 affaires plaidées** (sessions OT2015 à OT2023), couvrant **13 juges** et **4 569 votes individuels codés**, à partir de deux sources publiques : la *Supreme Court Database* (votes et décisions) et *CourtListener* (textes des opinions). Le corpus a ensuite été *gelé* : chaque fichier est accompagné de son empreinte cryptographique SHA-256, ce qui permet à quiconque de vérifier que les données utilisées dans les résultats sont exactement celles qui ont été publiées, et qu’aucune ligne n’a été modifiée après coup. L’intégralité du projet a été menée à budget strictement nul : données publiques, matériel de calcul standard et outils gratuits. Ce point n’est pas anecdotique : il démontre qu’une démarche scientifique complète est accessible à des élèves, sans laboratoire ni financement.

La méthode : une barre difficile, puis une épreuve scellée

La démarche comporte deux temps. *Premièrement*, fixer une barre honnête : avant de tester un modèle de langage, nous avons mesuré ce que donne une règle simple — pour chaque juge, prédire systématiquement le côté (conservateur ou libéral) que ce juge favorise d’habitude. Cette règle idéologique atteint **63,7 % des votes individuels** sur la fenêtre d’évaluation (intervalle de confiance à 95 % : [61,3 ; 65,9]). Tout challenger doit battre ce score pour prétendre apporter quelque chose. *Deuxièmement*, l’épreuve scellée : nous avons mis de côté 50 décisions serrées (résolues 5–4) mises sous scellés cryptographiques. Quatre conditions ont produit leurs prédictions *avant* que la moindre réponse ne soit consultée, puis les prédictions elles-mêmes ont été hachées et publiées, et la correction n’a été exécutée qu’une seule fois : — **A — zéro-shot** : un modèle de langage lit le dossier et prédit l’issue ;

- **B — persona** : le même modèle, auquel on a « appris » un juge particulier, via un prompt biographique et un adaptateur affiné (QLoRA) sur les opinions passées de ce juge ;
- **C — retrieval** : le dossier enrichi de précédents judiciaires récupérés automatiquement ;
- **D — prior idéologique re-ajusté** : la règle simple, recalibrée sur les données les plus récentes.

Les résultats clés

Condition	Décision de l'affaire	Vote individuel
A — zéro-shot	61,22 % (30/49)	56,23 % (203/361)
B — persona (QLoRA)	59,18 % (29/49)	59,83 % (216/361)
C — retrieval	53,06 % (26/49)	50,14 % (181/361)
D — prior idéologique	50,00 % (24/48)	75,91 % (312/411)

Le message principal est un *résultat négatif honnête* : sur les cinquante affaires les plus serrées, aucune condition de langage ne bat la barre idéologique, et la personnalisation ne détecte aucune amélioration (persona 59,18 % contre zéro-shot 61,22 % ; test exact de McNemar, $p = 1,00$). Le prior idéologique, lui, s'effondre à pile-ou-face au niveau de l'affaire (50 %) tout en dominant toutes les conditions de langage au niveau du vote (75,9 %) : savoir *qui* vote reste plus informatif que savoir *comment* le juge écrit. Les découvertes secondaires sont tout aussi instructives : les neuf personae simulées votent toutes plus conservatrices que le juge qu'elles imitent ; le prompt biographique, et non l'adaptateur affiné, fait l'essentiel du déplacement des votes ; l'hypothèse stylistique pré-enregistrée sur la qualité des personae est contredite par les données (corrélation de Spearman $\rho = -0,72$) ; et les personae se trompent sur les affaires mêmes sur lesquelles elles ont été entraînées.

Ce que nous en concluons — et nos limites assumées

Une part mesurable de la décision judiciaire — environ six votes sur dix — est extractible de l'historique public d'un juge ; mais sur les affaires qui se jouent à une voix, cette statistique s'évanouit, et le style rédactionnel d'un juge n'ajoute rien de détectable. Nous affichons nos limites comme une composante du travail scientifique : avec 49 affaires appariées, seule une amélioration de l'ordre de quinze à vingt points aurait été détectable ; une partie des affaires scellées était potentiellement déjà connue du modèle de base (contamination du pré-entraînement), même si le contraste principal — persona contre zéro-shot — partage la même base et annule cette contamination en différence ; le pipeline informatique a été audité par un seul des deux auteurs ; et la chronologie fine de l'analyse stylistique ne peut pas être établie par les seuls horodatages git. Ces limites sont discutées une à une dans le rapport complet.

Reproductibilité et accès

Tout est public et rejouable : code Python, corpus gelé, prédictions scellées, journaux et scripts d'audit sur le dépôt GitHub du projet. Un audit interne hostile a re-calculé chaque chiffre de ce résumé à partir des artefacts primaires, avec concordance à quatre décimales près. La science qui ne montre pas ses données n'est pas de la science ; nous avons donc construit le projet pour que chaque affirmation de cette page puisse être vérifiée, réfutée ou rejouée par un tiers, y compris avec les moyens d'un lycée.

Deux élèves de lycée, un protocole scientifique complet : question, données gelées, baselines pré-enregistrées, épreuve scellée, statistiques appariées, audit indépendant — et un résultat négatif assumé. Legally Subjective, github.com/Vitalcheffe/legally-subjective